

Pregunta 2.

1. Construya un ejemplo amano 3×4 , i.e., 3 variables predictoras y una a predecir, en el que se verifique que da el mismo resultado si los β 's se calculan usando la forma clásica...

$$\text{Sea } X = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad \text{y} \quad Y = \begin{pmatrix} 3 \\ 4 \\ 2 \end{pmatrix}$$

Aplicando a cada columna de X Gram-Schmidt se tiene.

$$u_1 = x_1 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$$

$$u_2 = x_2 - \frac{\langle u_1, x_2 \rangle}{\langle u_1, u_1 \rangle} u_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} - \frac{\langle \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \rangle}{\langle \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \rangle} \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

$$u_3 = x_3 - \frac{\langle u_1, x_3 \rangle}{\langle u_1, u_1 \rangle} u_1 - \frac{\langle u_2, x_3 \rangle}{\langle u_2, u_2 \rangle} u_2 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

$$\Rightarrow e_1 = \frac{u_1}{\|u_1\|} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \quad e_2 = \frac{u_2}{\|u_2\|} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad e_3 = \frac{u_3}{\|u_3\|} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

$$\text{Ahora} \quad X \cdot \beta = \langle y, e_1 \rangle e_1 + \langle y, e_2 \rangle e_2 + \langle y, e_3 \rangle e_3$$

$$= 4e_1 + 3e_2 + 5e_3$$

$$= \begin{pmatrix} 3 \\ 4 \\ 2 \end{pmatrix} = Y$$

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^t = \begin{pmatrix} a & c \\ b & d \end{pmatrix}$$

Con el método de regresión

$$\begin{aligned} \beta &= (X^t X)^{-1} X^t y = \left(\begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}^t \begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \right)^{-1} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 4 \\ 2 \end{pmatrix} \\ &= \left(\begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \right)^{-1} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 4 \\ 2 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 0 \\ 0 & 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 4 \\ 7 \\ 2 \end{pmatrix} \\ &= \begin{pmatrix} 2 & -1 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 4 \\ 7 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ 3 \\ 2 \end{pmatrix} \quad \therefore \beta = \begin{pmatrix} 1 \\ 3 \\ 2 \end{pmatrix} \end{aligned}$$

$$\Rightarrow y = X \cdot \beta = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 3 \\ 4 \\ 2 \end{pmatrix} \quad \therefore \text{Si se llega con ambos al mismo } y.$$

2 Pba. Sea $A \in \mathbb{R}^{n \times m}$, $b \in \mathbb{R}^n$, $x \in \mathbb{R}^m$.

Sea $y = Pb \in \text{Rango}(A)$; P es la proyección ortogonal y minimiza $\|r\|_2 = \|Ax - b\|_2$

Ahora sea $z \in \text{Rango}(A)$ con $z \neq y$.

$$\begin{aligned} z - y \text{ es ortogonal a } b - y &\Rightarrow \|b - z\|_2^2 = \|b - y\|_2^2 + \|y - z\|_2^2 \\ &\Rightarrow \|b - z\|_2 > \|b - y\|_2; \quad \forall z. \end{aligned}$$

Por lo tanto y minimiza $\|b - z\|_2$, entonces $Ax = Pb \in \text{Rango}(A)$

Pregunta C: Demuestre que Ridge puede ser obtenido mediante Regresión Lineal usando una versión aumentada de la tabla de datos. Se aumenta X con p filas adicionales $\sqrt{\lambda} I$ y se aumenta y con p ceros:

$$\tilde{X} = \begin{bmatrix} X \\ \sqrt{\lambda} I \end{bmatrix}, \quad \tilde{y} = \begin{bmatrix} y \\ 0 \end{bmatrix}$$

donde $\vec{0} = (0, 0, \dots, 0)^T$, osea \tilde{X} es de tamaño $(n+p) \times m$ que y es de tamaño $(n+p) \times 1$. Mediante ...

Sea X una tabla $n \times m$ y y un vector.

$$\Rightarrow \tilde{X} = \begin{pmatrix} X \\ \sqrt{\lambda} I \end{pmatrix}; \quad \tilde{y} = \begin{pmatrix} y \\ 0 \end{pmatrix}$$

\tilde{X} es de dimensión $(n+p) \times m$ y \tilde{y} $(n+p) \times 1$.

$$\Rightarrow X^t = [X^t \quad \sqrt{\lambda} I^t]$$

$$\text{Ahora } \beta = (X^t \tilde{X})^{-1} \tilde{X}^t \cdot \tilde{y}$$

$$= \left(\left(X^t \sqrt{\lambda} I^t \right) \begin{pmatrix} X \\ \sqrt{\lambda} I \end{pmatrix} \right)^{-1} \left(X^t \sqrt{\lambda} I \right) \begin{pmatrix} y \\ 0 \end{pmatrix}$$

$$= (X^t X + \lambda I)^{-1} X^t y + \sqrt{\lambda} I \cdot \vec{0}$$

$$= (X^t X + \lambda I)^{-1} X^t y //$$

Pregunta 7.

Regresión con modelo de p parámetros, ajustados por mínimos cuadrados. en un conjunto de datos de entrenamiento $(x_1, y_1), \dots, (x_n, y_n) \dots$

• Sea $\hat{\beta}$ estimado de mínimos cuadrados.

• datos prueba $(\tilde{x}_1, \tilde{y}_1), \dots, (\tilde{x}_m, \tilde{y}_m)$.

$$\text{Si } R_{tr}(\beta) = \frac{1}{n} \sum_{i=1}^n (y_i - x_i \beta)^2 \text{ y } R_{te}(\beta) = \frac{1}{m} \sum_{i=1}^m (\tilde{y}_i - \tilde{x}_i \beta)^2.$$

Pruebe :

$$E[R_{tr}(\hat{\beta})] \leq E[R_{te}(\hat{\beta})].$$

donde la esperanza es calculada ~~per~~ para todo el espacio aleat....

La esperanza de $R_{te}(\beta)$ es igual a la esperanza de $(\tilde{y}_i - \beta \tilde{x}_i)^2$, por lo tanto es independiente de m .

Tomando $m=n$ y sustituyendo en R_{te} $\hat{\beta}$ por β que minimiza la expresión, tendríamos que las medias de ambas son iguales.

Pregunta 8

a) Ejecutamos una regresión Ridge con parámetro λ en X . Se obtiene el coeficiente α . Ahora incluimos una copia exacta $X^* = X$ y volvemos a calcular Ridge. Demuestre que ambos coef. son iguales y calcule su valor. Demuestre en general que si m copias de la variable X_j son incluidas, todos sus coef. son iguales.

Ridge selecciona β para minimizar

$$\|y - \beta X\|^2 + \lambda \|\beta\|^2$$

el mínimo está dado por

$$\beta = (X^T X + \lambda I)^{-1} X^T y$$

Como X es de una sola variable, i.e., $p=1$, esto quiere decir que $X^T X$ es un escalar y su inversa también es un escalar. 1.

$$\Rightarrow \beta = \frac{X^T y}{X^T X + \lambda I}$$

Cuando incluimos una copia exacta, el problema de optimización se vuelve

$$\|y - X\beta_1 - X\beta_2\|^2 + \lambda \|\beta_1\|^2 + \lambda \|\beta_2\|^2$$

$$\Rightarrow \sum_{i=1}^n (y_i - x_i \beta_1 - x_i \beta_2)^2 + \lambda \beta_1^2 + \lambda \beta_2^2 ; \text{ pues } \beta_1, \beta_2 \text{ son escalares}$$

Derivando

$$2 \sum_{i=1}^n (y_i - x_i \beta_1 - x_i \beta_2) (-x_i) + 2 \lambda \beta_1 = 0$$

$$2 \sum_{i=1}^n (y_i - x_i \beta_1 - x_i \beta_2) (-x_i) + 2 \lambda \beta_2 = 0$$

en una forma matricial esto es: y por regla de Cramer.
la solución es:

$$\begin{pmatrix} X^T X + \lambda & -X^T X \\ -X^T X & X^T X + \lambda \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix}$$

$$\Rightarrow \frac{X^T y}{2X^T X + \lambda} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} \quad \text{nota: } \beta_1 = \beta_2$$

que era lo que buscábamos probar.

Ahora para m copias, el problema de optimización sería:

$$\left(y - X \sum_{j=1}^m \beta_j \right)^T \left(y - X \sum_{j=1}^m \beta_j \right) + \lambda \sum_{j=1}^m \beta_j^2$$

derivando e igualando a cero tenemos:

$$-X^T \left(y - X \sum_{j=1}^m \beta_j \right) - \left(y - X \sum_{j=1}^m \beta_j \right) X + 2\lambda \beta_k = 0; \quad \forall k \in \{1, \dots, m\}$$

Lo cual podemos escribir como

$$X^T X \sum_{j=1}^m \beta_j + \lambda \beta_k = X^T y$$

Tomando otro $\beta_k \in \{\beta_1, \dots, \beta_m\}$ tendríamos las mismas ecuaciones.

$$\Rightarrow m X^T X \beta_k + \lambda \beta_k = X^T y$$

$$\Rightarrow \beta_k = \frac{X^T y}{m X^T X + \lambda}; \quad \forall k \in \{1, \dots, m\}$$